

ZPRACOVÁNÍ OBRAZU

HRANY V OBRAZE – DETEKCE A VYUŽITÍ

Víťa Beran



Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 1/2, 612 66 Brno

- Jak zvýraznit a nalézt důležité aspekty v obraze?
- Co je to hrana?
- Co je výsledkem detekce hran?
- Jak v obraze zvýraznit hrany?
- Jak pracují operátory 1. a 2. derivace?
- Co je to Laplaceův a k čemu lze využít?
- Co je to Houghova transformace a k čemu slouží?
- Jaké pokročilé metody jsou na detekci hran založeny?



Hrany

Co je to hrana v obraze? A gradient?

Rozdíl – zvýraznění nebo detekce?

Proč je pro nás analýza hran užitečná?

Fyzické rozmístění objektů v obraze je naznačeno prudší změnou jasu.

citlivost na změny v obraze – hrany

hrany dělí obraz na jeho části – regiony

dělení obrazu (segmentace)


důležitá část pro další analýzu obrazu

závisí na interpretaci obrazu


objekt – zájmový region

zbytek obrazu je pozadí


- Hrana – pixely obrazu, kde se hodnota jasu prudce mění,
- hrana na úrovni pixelu je reprezentována
 - velikostí $|G|$ a
 - směrem Φ ,
- funkce pixelu a jeho okolí.




- Jak může vypadat jádro konvoluce pro výpočet změny ve směru x a y ?



- Jaká je odezva na tyto jádra?
- Jakou bude mít velikost a směr výsledný gradient?



- Jak je tento postup odolný vůči šumu?
- Jak to vylepšit? Navrhněte jiné jádro.




$$\frac{1}{2} \begin{bmatrix} 0 & 0 & 0 \\ -1 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\frac{1}{2} \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$|G| = \sqrt{G_x^2 + G_y^2}$$

$$\phi = \arctan\left(\frac{G_y}{G_x}\right)$$

- Jaká je odezva na tyto jádra?
- Jakou bude mít velikost a směr výsledný gradient?




$$\frac{1}{8} \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\frac{1}{8} \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

$$|G| = \sqrt{G_x^2 + G_y^2}$$

$$\phi = \arctan\left(\frac{G_y}{G_x}\right)$$

- Co způsobilo tuto změnu?
- Jak se tomu dá předejít?



$$\frac{1}{8} \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\frac{1}{8} \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

$$|G| = \sqrt{G_x^2 + G_y^2}$$

$$\phi = \arctan\left(\frac{G_y}{G_x}\right)$$



filtrace obrazu

odstranění vzorkovacího či kvantovacího šumu, rozmazání, apod.,

diferenciace

zvýraznění oblastí s výraznou změnou intenzity,


detekce

prahování, průchod nulou, ...

- Využití 2D Gaussova operátoru pro rozmazání

$$g(i, j, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{i^2+j^2}{2\sigma^2}}$$

- kde σ je směrodatná odchylka
 - velikost okolí ovlivňující pixel.




$$L(i, j, \sigma) = g(i, j, \sigma) * f(i, j)$$

$\frac{1}{273}$

1	4	7	4	1
4	16	26	16	4
7	26	41	26	7
4	16	26	16	4
1	4	7	4	1

$$g(i, j, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{i^2 + j^2}{2\sigma^2}}$$




• První derivace


- Sobel, ...
- porovnání s prahem,

• Druhá derivace


- Laplacián, ...
- průchod nulou,



- Parametrické modely hran
 - přesnější popis hran,
 - náročné na výpočet,
 - např. Houghova transformace, ...



- odolnost vůči šumu
- lokalizace
- četnost odezvy



Dobrá detekce

velikost poměru signál-šum je co největší, aby pravděpodobnost selhání výběru hrany byla co nejmenší.

Dobrá lokalizace

vybrané hranové body by měly být co nejbližší středu hrany.

Jedinečná odezva

měla by existovat jen jedinečná odezva na skutečnou hranu.

Analytická realizace není kvůli složitosti podmínek možná.

Modely hran: Skoková (step), náběžná (ramp), impulsní (line), střechová (roof).

- diskrétní obraz
 - derivace aproximována diferencí

$$L(i, j) = f(i, j) * h$$

$$h_1 = \begin{bmatrix} 0 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}; h_2 = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

analýza malého lokálního okolí

konvoluce s jádrem hranového operátoru

detekce směru hrany vyžaduje množinu jader korespondujících s určitými směry

velká závislost na velikost objektu v obraze

citlivost na šum

- Sobelův, Kirschův, Robinsonův a Prewittův op.
- Operátory aproximující první derivaci,
- nazývané kompas operátory díky schopnosti detekovat směr gradientu (hrany),
- gradient je počítán pro všech 8 směrů, maximální pak určuje směr.

$$L(i, j) = \max \{|L_1(i, j)|, \dots, |L_m(i, j)|\}$$

$$L_m(i, j) = f(i, j) * h_m$$

- Robertsův operátor
 - málo pixelů použito k výpočtu gradientu
 - velká citlivost na šum

$$h_1 = \begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}; h_2 = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

- Prewittův operátor
 - více pixelů použito k výpočtu gradientu
 - nižší citlivost na šum

$$h_1 = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}; h_2 = \begin{bmatrix} 0 & 1 & 1 \\ -1 & 0 & 1 \\ -1 & -1 & 0 \end{bmatrix}; \dots$$

- Kirschův operátor

$$h_1 = \begin{bmatrix} 3 & 3 & 3 \\ 3 & 0 & 3 \\ -5 & -5 & -5 \end{bmatrix}; h_2 = \begin{bmatrix} 3 & 3 & 3 \\ -5 & 0 & 3 \\ -5 & -5 & 3 \end{bmatrix}; \dots$$

- Robinsonův operátor

$$h_1 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -2 & 1 \\ -1 & -1 & -1 \end{bmatrix}; h_2 = \begin{bmatrix} 1 & 1 & 1 \\ -1 & -2 & 1 \\ -1 & -1 & 1 \end{bmatrix}; \dots$$

- možné použít pouze dvě masky
 - detekce horizontálních a vertikálních hran

$$h_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}; h_2 = \begin{bmatrix} 0 & -1 & -2 \\ 1 & 0 & -1 \\ 2 & 1 & 0 \end{bmatrix}; \dots$$

- výsledná hodnota gradientu:


$$L(i, j) = \sqrt{L_i(i, j)^2 + L_j(i, j)^2}$$

- možno aproximovat:

$$\tilde{L}(i, j) = |L_i(i, j)| + |L_j(i, j)|$$

- směrnice gradientu je potom:

$$\theta(i, j) = \arctan \frac{L_j(i, j)}{L_i(i, j)}$$




detektor hran realizován tak, aby co nejlépe vyhověl:

Detekce, lokalizace, jedinečná odezva


1. rozmazání (Gauss) a 1. derivace
2. potlačením nemaximálních hodnot (non-maxima suppression),
3. prahování s hysterezí.

- Operátor první derivace Gaussovske funkce

$$\nabla(g(i, j, \sigma) * f(i, j))$$



- potlačením nemaximálních hodnot
- ve směru gradientu potlač pixely, které nejsou lokálním maximem




- potlačením nemaximálních hodnot



- prahování s hysterezí

- Silné hrany ($> \text{High}$) jsou ponechány, slabé pouze pokud jsou spojeny s nějakou silnější hranou.
- Velmi slabé hrany ($< \text{Low}$) potlačeny.



- Prahujte následující signál: 1 – je hrana, 0 – není hrana
- Low: 3, High: 9

10	2	7	8	2	4	10	9	1

- Laplacián

- Suma parciálních derivací nezávislých proměnných

$$\nabla^2 f(i, j) = \frac{\partial^2 f(i, j)}{\partial^2 i} + \frac{\partial^2 f(i, j)}{\partial^2 j}$$



- Laplacián Gaussovy funkce

$$\nabla^2 (g(i, j, \sigma) * f(i, j))$$

$$H = \frac{1}{4} \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

$$H = \frac{1}{8} \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

$$H = \frac{1}{8} \begin{bmatrix} -2 & 1 & -2 \\ 1 & 4 & 1 \\ -2 & 1 & -2 \end{bmatrix}$$



Operátory 2. derivace obecně

+

Detekce průchodu nulou, snazší detekce než hledání extrému

-

příliš velké vyhlazení obrazu,

ztráta ostrých rohů,

tendence vzniku uzavřených smyček hran.

Laplacián Gaussovy funkce

Invariantní vůči rotaci - nedetekuje orientaci (izotropní)

normalizovaná impulsová odezva Laplaciánu se 4-okolím, 8-okolím a separabilní s 8-okolím



Konvoluce obrazu s Laplaciánem Gaussovy funkce

Detekce průchodu nulou

Někdy znám jako - Mexický klobouk

+

velice stabilní a robustní metoda měření změn v obraze a jejich detekcí

lokalizace nuly v místě hrany

vliv většího okolí pixelu - velikost jádra, např. pro $\sigma = 4$, jádro asi 40 pixelů široké


-



falešné hrany

nepřesná lokalizace hrany



- Aproximace LoG
- Chová se jako pásmová propust

$$\tilde{\nabla}_{norm}^2 L(i, j, \sigma) = \frac{1}{2\Delta\sigma} (L(i, j, \sigma + \Delta\sigma) - L(i, j, \sigma - \Delta\sigma))$$





$$\rho = x \cos \theta + y \sin \theta$$



Parametrické vyjádření přímky

kde ρ je normalizovaná vzdálenost přímky od počátku a θ je úhel vzhledem k ose x .


Body obrazu jsou v parametrickém prostoru ρ, θ prezentovány křivkami (sinusoidy).

Jedná-li se o kolineární body (z jedné přímky), křivky v parametrickém prostoru se protínají.

Průnik reprezentuje parametry hledané křivky.

Jakou prezentaci má bod z parametrického prostoru v obrazovém prostoru?

$$\rho = x \cos \theta + y \sin \theta$$



θ	r
15	189.0
30	282.0
45	355.7
60	407.3
75	429.4

θ	r
15	318.5
30	376.8
45	407.3
60	409.8
75	385.3


θ	r
15	419.0
30	443.6
45	438.4
60	402.9
75	340.1

Consider three data points, shown here as black dots (example from wikipedia):

1. For each data point, a number of lines are plotted going through it, all at different angles. These are shown here in different colours.
2. To each line, a support line exists which is [perpendicular](#) to it and which intersects the [origin](#). In each case, one of these is shown as an arrow.
3. The length (i.e. perpendicular distance to the origin) and angle of each support line is calculated. Lengths and angles are tabulated below the diagrams.

From the calculations, it can be seen that in either case the support line at 60° has a similar length. Hence, it is understood that the corresponding lines (the blue ones in the above picture) are very similar. One can thus assume that all points lie close to the blue line.

$$(i - a)^2 + (j - b)^2 = r^2$$



Stejný princip se používá i pro hledání dalších křivek, které je možné popsat parametricky

Kružnice, křivky, elipsy apod.

Kružnice

Pro hranové body hledáme parametry a a b , pro které platí r hledané kružnice.

Hledáme-li i r , musíme rozšířit Houghův prostor do 3D.

Houghovy transformace se dá použít i na detekci tvarů, které nejde přímo popsat parametricky

Obecná Houghova transformace.

- Reprezentace diskrétní křivkou


$$v = \{v_1, \dots, v_n\}, v_i = [x_i, y_i], n = 1, \dots, N$$

- Deformace vlivem vnitřních a vnějších sil.

$$E(v) = E_{\text{int}}(v) + E_{\text{ext}}(v)$$

$$E_{\text{int}}(v) = \sum_{i=1}^N u_i |2\alpha_i - \alpha_{i+1} - \alpha_{i-1}|^2 + \sum_{i=1}^N w_i |2v_i - v_{i+1} - v_{i-1}|^2$$

$$E_{\text{ext}}(v) = \sum_{i=1}^N P(x_i, y_i), \text{ kde } P(x, y) = -c |\nabla [G_\sigma * I(x, y)]|$$



Výsledná pozice kontury v koresponduje s minimem její energie $E(v)$

$u, w \dots$ parametry kontrolující tuhost a rozpínavost kontury,

$c \dots$ je konstanta.

Vnitřní síly ovlivňují **hladkost křivky**.

Vnější (**obrazové**) síly **tvarují konturu směrem ke hranám objektu**.


Iterativní metoda. Cílem je tyto síly vybalancovat.

Kolik vnitřní a vnější energie je potřeba, aby se kontura *udržel* v tvaru ... a, b, c, d?

Interní/Externí energie

Křivka je vyhlazená a
obepíná hranice objektu






Často nutná manuální inicializace kontury.



Input
example




Average
gradients



Weighted
pos wts



Weighted
neg wts



- M. Sonka, V. Hlavac, R. Boyle. Image Processing, Analysis and Machine Vision (3rd edition). Thomson Learning. 2007
- Hlaváč, V., Sedláček, M.: Zpracování signálů a obrazů, Skriptum, Vydavatelství ČVUT, 2002.
- Pratt, W., K.: Digital Image Processing: PIKS Inside, Third Edition. John Wiley & Sons, Inc. 2001.